

Лекція №2

Транслятори і формальні граматики

Основні визначення

У прикладах для нижчеприведених визначень будемо використовувати граматику для цілого десяткового числа:

1. $\langle \text{число} \rangle \rightarrow \langle \text{рядок цифр} \rangle$
2. $\langle \text{рядок цифр} \rangle \rightarrow \langle \text{цифра} \rangle$
3. $\langle \text{рядок цифр} \rangle \rightarrow \langle \text{рядок цифр} \rangle \langle \text{цифра} \rangle$
4. $\langle \text{цифра} \rangle \rightarrow 0$
5. $\langle \text{цифра} \rangle \rightarrow 1$
6. $\langle \text{цифра} \rangle \rightarrow 2$
7. $\langle \text{цифра} \rangle \rightarrow 3$
8. $\langle \text{цифра} \rangle \rightarrow 4$
9. $\langle \text{цифра} \rangle \rightarrow 5$
10. $\langle \text{цифра} \rangle \rightarrow 6$
11. $\langle \text{цифра} \rangle \rightarrow 7$
12. $\langle \text{цифра} \rangle \rightarrow 8$
13. $\langle \text{цифра} \rangle \rightarrow 9$

Визначення 1. Рядок α безпосередньо породжує рядок β ($\alpha \Rightarrow \beta$), якщо $\alpha = \gamma_1 \langle U \rangle \gamma_2$, $\beta = \gamma_1 \delta \gamma_2$, та існує правило $\langle U \rangle \rightarrow \delta$, де $\alpha, \beta, \delta, \gamma_1, \gamma_2 \in V^*$, $\langle U \rangle \in N$, або, можна сказати інакше: рядок β безпосередньо виводиться з рядка α .

Приклад.

Побудувати число 22 за вищенаведеною граматикою.

Процес побудови:

| № правила | α | Дія | β | Лівий контекст γ_1 | Правий контекст γ_2 |
|-----------|--|---------------|--|---------------------------|--------------------------------|
| 1 | $\langle \text{число} \rangle$ | \Rightarrow | $\langle \text{рядок цифр} \rangle$ | ϵ | ϵ |
| 3 | $\langle \text{рядок цифр} \rangle$ | \Rightarrow | $\langle \text{рядок цифр} \rangle \langle \text{цифра} \rangle$ | ϵ | ϵ |
| 2 | $\langle \text{рядок цифр} \rangle \langle \text{цифра} \rangle$ | \Rightarrow | $\langle \text{цифра} \rangle \langle \text{цифра} \rangle$ | ϵ | $\langle \text{цифра} \rangle$ |
| 6 | $\langle \text{цифра} \rangle \langle \text{цифра} \rangle$ | \Rightarrow | $2 \langle \text{цифра} \rangle$ | ϵ | $\langle \text{цифра} \rangle$ |
| 6 | $2 \langle \text{цифра} \rangle$ | \Rightarrow | 22 | 2 | ϵ |

Результуючий ланцюжок виводу матиме вигляд:

$\langle \text{число} \rangle \Rightarrow^1 \langle \text{рядок цифр} \rangle \Rightarrow^3 \langle \text{рядок цифр} \rangle \langle \text{цифра} \rangle \Rightarrow^2 \langle \text{цифра} \rangle \langle \text{цифра} \rangle \Rightarrow^6 2 \langle \text{цифра} \rangle \Rightarrow^6 22$.

Визначення 2. Кажуть, що рядок α породжує рядок β , якщо існує ланцюжок виводів:

$$\alpha = \gamma_0 \Rightarrow \gamma_1 \Rightarrow \gamma_2 \Rightarrow \dots \Rightarrow \gamma_n = \beta.$$

Породження позначається $\alpha \Rightarrow^+ \beta$, якщо β виводиться з α більш ніж за один крок.

Породження позначається $\alpha \Rightarrow^* \beta$, якщо може бути одна з двох ситуацій: $\alpha \Rightarrow^+ \beta$ або $\alpha \Rightarrow \beta$.

Наприклад:

- 1) $\langle \text{число} \rangle \Rightarrow^* 22$
- 2) $\langle \text{число} \rangle \langle \text{цифра} \rangle \Rightarrow^* 22$
- 3) $\langle \text{число} \rangle \langle \text{цифра} \rangle \Rightarrow^+ 22$

Для заданої граматики записи 2) і 3) є однаково коректними.

Визначення 3. Сентенцією або реченням граматики G називається рядок, що складається лише з термінальних символів і виводиться з аксіом граматики.

Визначення 4. Сентенціальною формою граматики G з аксіомою S називається будь-який рядок термінальних та/або нетермінальних символів, що виводиться з аксіом граматики.

Визначення 5. Мовою L граматики G називається множина всіх сентенцій (речень), які можуть бути породжені граматиною G .

Класифікація мов за Хомським.

Ноам Хомський (Аврам Ноум Хомски (Чомски)) (Avram Noam Chomsky) народився у 1928 році у Філадельфії штат Пенсільванія, у єврейській родині. Його батьки — відомий гебраїст, професор Уільям Хомський (William Chomsky, 1896—1977, народився у містечку Купель Волинської губернії) і Елсі Симоновська (народилась у Бобруйську). Фраза з інтерв'ю Хомського (Noam Chomsky): My father came from the Ukraine... — «Мій батько походить з України».

Класифікація формальних мов була вперше викладена в книзі «Синтаксичні структури» у 1957 році. Згідно з цією класифікацією існує чотири типи формальних граматик і, відповідно, формальних мов.

- Граматика типу 0 має правила вигляду

$$\alpha \rightarrow \beta,$$

де $\alpha \in V^+$, $\beta \in V^*$.

До даного типу відносяться всі природні мови.

- Граматика типу 1 має правила виду

$$\alpha \langle u \rangle \beta \rightarrow \alpha \gamma \beta,$$

де $\alpha, \gamma, \beta \in V^*$, $\langle u \rangle \in N$, α – лівий контекст, β – правий контекст.

Мови, що породжуються граматиками типу 1, називаються **контекстно-залежними мовами** (КЗ-мовами) або **мовами безпосередніх складових** (БС-мовами).

- Граматика типу 2 має правила вигляду

$$\langle u \rangle \rightarrow \alpha,$$

де $\langle u \rangle \in N$, $\alpha \in V^*$.

Такі граматики називаються **контекстно-вільними** граmaticами, що породжують **контекстно-вільні мови** (КВ-мови).

До КВ-мов відносяться практично всі мови програмування. Граматики типу 2 використовуються для побудови синтаксичних аналізаторів.

- Граматика типу 3 має правила тільки одного з двох наступних видів:

перший: $\langle u \rangle \rightarrow a$

$$\langle u \rangle \rightarrow a \langle v \rangle$$

або

другий: $\langle u \rangle \rightarrow a$

$$\langle u \rangle \rightarrow \langle v \rangle a$$

де $a \in T$, $\langle u \rangle \in N$, $\langle v \rangle \in N$.

Граматики типу 3 також називають **регулярними** або **автоматними** граmaticами. Мови, які породжуються такими граmaticами, називаються **регулярними мовами**.

Визначення деяких властивостей граmatic

1. Еквівалентність граmatic.

Граматики називаються еквівалентними, якщо вони породжують одну і ту ж саму мову.

Наведені нижче граматики 1 та 2 є еквівалентними:

Граматика 1:

- $\langle \text{рядок} \rangle \rightarrow \langle \text{рядок символів} \rangle$
- $\langle \text{рядок символів} \rangle \rightarrow a$
- $\langle \text{рядок символів} \rangle \rightarrow \langle \text{рядок символів} \rangle a$

Граматика 2:

- $\langle \text{рядок} \rangle \rightarrow \langle \text{рядок символів} \rangle$
- $\langle \text{рядок символів} \rangle \rightarrow \langle \text{символ} \rangle$
- $\langle \text{рядок символів} \rangle \rightarrow \langle \text{рядок символів} \rangle \langle \text{символ} \rangle$
- $\langle \text{символ} \rangle \rightarrow a$

2. Однозначність граmaticи.

Граматика називається однозначною, якщо для будь-якого речення, породжуваного цією граmaticою, всі можливі схеми його виводу приводять до одного і того ж дерева виводу.

3. Неоднозначність граmaticи.

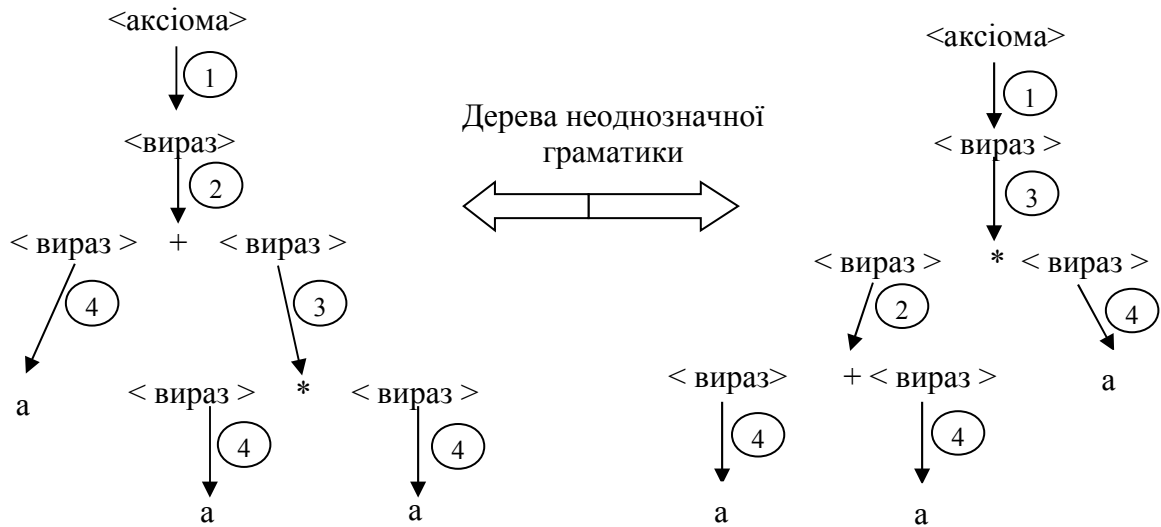
Граматика називається неоднозначною, якщо для одного і того ж речення, породжуваного граmaticою, існує декілька неспівпадаючих дерев виводу.

Наприклад, для граmaticи

- $\langle \text{аксіома} \rangle \rightarrow \langle \text{вираз} \rangle$
- $\langle \text{вираз} \rangle \rightarrow \langle \text{вираз} \rangle + \langle \text{вираз} \rangle$
- $\langle \text{вираз} \rangle \rightarrow \langle \text{вираз} \rangle * \langle \text{вираз} \rangle$
- $\langle \text{вираз} \rangle \rightarrow a$

можливі наступні різні дерева виводу:

a+a*a



Якщо цю граматику переписати інакше, то отримаємо однозначну граматику вигляду

1. <аксіома> → <вираз>
2. <вираз> → <терм>
3. <вираз> → <вираз>+<терм>
4. <терм> → <множник>
5. <терм> → <терм>*<множник>
6. <множник> → a

Примітка. В термінології формальних граматик під терміном «терм» розуміють вираз, що складається лише з множників.

Деякі властивості КВ-граматик

1. Будь-яку ε-вільну КВ-граматику можна привести до **нормальної форми Грейбах** з правилами вигляду:

$$\langle x \rangle \rightarrow b\alpha,$$

де $b \in T$, $\alpha \in N^*$, тобто α - рядок нетерміналів, можливо порожній.

2. Будь-яку ε-вільну КВ-граматику можна привести до **нормальної форми Хомського** з правилами вигляду:

$$1. \langle x \rangle \rightarrow \langle A \rangle \langle B \rangle,$$

$$2. \langle x \rangle \rightarrow b,$$

де $\langle x \rangle, \langle A \rangle, \langle B \rangle \in N$; $b \in T$.

Приклад. Привести до нормальної форми Хомського граматику

$$1. \langle U \rangle \rightarrow \langle A \rangle \langle b \rangle \langle Z \rangle \langle Y \rangle$$

$$2. \langle b \rangle \rightarrow b$$

Введемо правило: $\langle U1 \rangle \rightarrow \langle A \rangle \langle b \rangle \langle Z \rangle$,

тоді: $\langle U \rangle \rightarrow \langle U1 \rangle \langle Y \rangle$.

Введемо правило: $\langle U2 \rangle \rightarrow \langle A \rangle \langle b \rangle$,

тоді: $\langle U1 \rangle \rightarrow \langle U2 \rangle \langle Z \rangle$.

Тобто замість грамматики

1. $\langle U \rangle \rightarrow \langle A \rangle \langle b \rangle \langle Z \rangle \langle Y \rangle$
2. $\langle b \rangle \rightarrow b$

отримаємо грамматику у нормальній формі Хомського:

1. $\langle U \rangle \rightarrow \langle U1 \rangle \langle Y \rangle$
2. $\langle U1 \rangle \rightarrow \langle U2 \rangle \langle Z \rangle$
3. $\langle U2 \rangle \rightarrow \langle A \rangle \langle b \rangle$
4. $\langle b \rangle \rightarrow b$.

3. Для будь-якої КВ-мови L з граматикою G існує ϵ -вільна КВ-граматика G' , така що $L(G') = L(G) \setminus \{ \epsilon \}$.